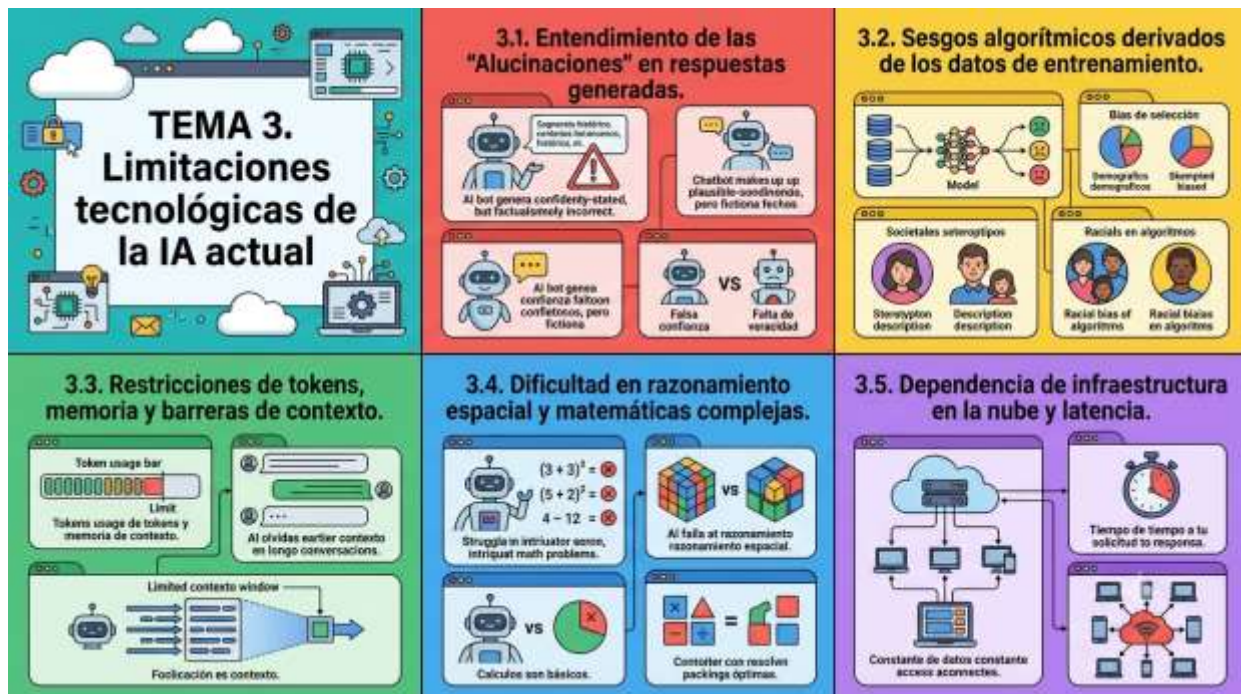


TEMA N° 3



TEMA 3 LIMITACIONES TECNOLÓGICAS DE LA IA ACTUAL



EN ESTE TEMA SERÁS CAPAZ DE...

1. **Identificar y mitigar** de manera crítica las "alucinaciones" y sesgos algorítmicos en los sistemas de Inteligencia Artificial, comprendiendo cómo afectan el desarrollo de soluciones informáticas locales.
2. **Evaluar las restricciones físicas y lógicas** de la IA, como la ventana de tokens, la memoria de contexto y la dependencia de la infraestructura en la nube, optimizando el uso de recursos tecnológicos en entornos con conectividad limitada.
3. **Analizar los desafíos prácticos** en el razonamiento lógico-matemático y espacial de los modelos actuales, permitiéndote como Técnico tomar decisiones acertadas sobre cuándo implementar IA y cuándo recurrir al desarrollo de software tradicional.



PRÁCTICA



Pregunta detonante: ¿Por qué una Inteligencia Artificial entrenada con millones de datos de todo el mundo puede afirmar con total seguridad que existe una línea de tren subterráneo en Pailón o equivocarse al calcular el inventario exacto de repuestos de motocicletas para un taller del Barrio Central Fátima?


El Desafío en el CEA Herman Ortiz Camargo: Imagina que estás trabajando en la sala de computo del nuevo módulo educativo del CEA Herman Ortiz Camargo, ubicado en el Barrio Saó. Como Técnico en Sistemas Informáticos, te han encomendado diseñar un asistente virtual basado en Inteligencia Artificial para ayudar a los comerciantes del Barrio Central Fátima (zona de alta actividad comercial e iglesias) y a los transportistas que operan cerca de la estación de tren en el Barrio 24 de Septiembre.

Al realizar las primeras pruebas con un Modelo de Lenguaje Grande (LLM) comercial para que genere descripciones de las rutas de entrega automáticas desde el Barrio Saó hasta los barrios más alejados como Las Misiones, San Expedito y Oto Waver, notas un comportamiento extraño:

1. El modelo genera descripciones geográficas increíblemente detalladas, pero completamente falsas. Afirma que el Coliseo Municipal del Barrio 27 de Mayo colinda directamente con el Barrio Jardines de Pailón, ignorando por completo la distribución real del municipio.
2. Al ingresar un documento extenso con la lista de precios de la canasta básica y herramientas agrícolas de los proveedores locales para que el sistema aprenda el contexto, la IA procesa las primeras páginas bien, pero a mitad del documento empieza a ignorar los datos del inicio, "olvidando" los productos del Barrio San Antonio y mezclando los códigos de inventario de las tiendas de abarrotes del Barrio Ovidio Barberi.
3. Cuando el internet de Entel o Tigo sufre interrupciones debido a los fuertes vientos o lluvias en Pailón, el asistente web simplemente deja de responder, mostrando errores de tiempo de espera (*timeout*) en la consola del navegador.



Este escenario real nos demuestra que la IA no es mágica ni infalible. Tiene límites tecnológicos muy claros que todo programador y administrador de sistemas debe conocer a fondo para evitar fallos críticos en producción.



TEORÍA




3.1. ENTENDIMIENTO DE LAS "ALUCINACIONES" EN RESPUESTAS GENERADAS

En el ámbito de la Inteligencia Artificial, una **alucinación** es la generación de contenido que parece completamente correcto, coherente y gramaticalmente perfecto, pero que es fácticamente falso o carece de sustento en los datos reales.

Los modelos de lenguaje no "piensan" ni comprenden la realidad como un ser humano; son motores estadísticos de predicción de palabras. Su función principal es calcular matemáticamente cuál es la palabra más probable que debe seguir a la anterior, basándose en los patrones de texto con los que fueron entrenados.

DIAGRAMA DE NEXT-TOKEN PREDICTION Y ALUCINACIONES EN LLMs



Si construyes un software para el control de asistencia de los estudiantes del CEA en el Barrio Saó y le pides a una IA no configurada que extraiga el historial médico o de notas de un alumno del



cual no tiene registros, el algoritmo rellenará los espacios vacíos calculando las palabras con mayor probabilidad estadística de sonar creíbles. El resultado será un reporte con nombres de materias inventadas, notas ficticias y fechas erróneas, presentado con un tono de absoluta certeza.

3.2. SESGOS ALGORÍTMICOS DERIVADOS DE LOS DATOS DE ENTRENAMIENTO

El principio fundamental de la informática "*Basura entra, basura sale*" (*Garbage In, Garbage Out*) se aplica perfectamente a la IA. Los modelos se entrenan con conjuntos masivos de datos descargados de internet, los cuales reflejan los prejuicios, desigualdades, visiones culturales y limitaciones de las personas que crearon esos contenidos. Un **sesgo algorítmico** ocurre cuando el modelo discrimina, excluye o prioriza sistemáticamente ciertas respuestas sobre otras debido a desequilibrios en su entrenamiento.

Si una cooperativa agrícola en el Barrio Central Fátima de Pailón utiliza un sistema automatizado de IA para evaluar créditos productivos de soya o girasol, y dicho sistema fue entrenado exclusivamente con datos financieros de grandes empresas de Norteamérica o Europa, el modelo rechazará las solicitudes locales. Esto se debe a que no comprenderá el modelo de producción de los pequeños productores chiquitanos, ni las dinámicas económicas de barrios locales como María Belén o San José. El programador debe identificar estos sesgos y balancear los datos introduciendo contexto local específico.

3.3. RESTRICCIONES DE TOKENS, MEMORIA Y BARRERAS DE CONTEXTO


Un modelo de IA no procesa letras o palabras completas de forma directa, sino que fragmenta el texto en unidades llamadas **tokens**. Un token puede ser una palabra corta, una sílaba o incluso un solo carácter.

La **ventana de contexto** es la cantidad máxima de tokens que un modelo puede leer y procesar simultáneamente en una sola interacción (tanto la pregunta del usuario como la respuesta de la máquina). Cada modelo de IA tiene un límite físico de memoria determinado por la arquitectura de su hardware (principalmente la memoria VRAM de las tarjetas gráficas donde se ejecuta).



Modelo de IA (Ejemplo)	Ventana de Contexto Aproximada	Capacidad de Procesamiento Real
GPT-3.5 Legacy	4.096 tokens	Equivale a unas 3 páginas de texto
GPT-4 o Claude 3	128.000 a 200.000 tokens	Equivale a libros enteros o códigos complejos
Modelos Locales Pequeños (Llama 3 8B)	8.192 tokens	Ideal para tareas rápidas en servidores locales

Cuando un Técnico intenta procesar el plan curricular de todas las carreras del CEA Herman Ortiz Camargo junto con las actas de notas históricas de los barrios Jardines de Pailón y Las Misiones, si el volumen de datos supera la ventana de contexto, el modelo sufrirá de "amnesia". Empezará a descartar los tokens más antiguos para dar espacio a los nuevos, provocando respuestas incoherentes o ignorando instrucciones dadas al inicio de la conversación.



3.4. DIFICULTAD EN RAZONAMIENTO ESPACIAL Y MATEMÁTICAS COMPLEJAS

A pesar de su potencia aparente, las IA basadas en arquitecturas Transformer tienen serias dificultades con el razonamiento espacial y el cálculo matemático estricto. Al ser herramientas lingüísticas y probabilísticas, no ejecutan operaciones matemáticas a través de un chip aritmético



tradicional, sino que intentan "recordar" o predecir el resultado basándose en ejemplos similares de su entrenamiento.


Si le pides a una IA que diseñe la distribución física de los cables de red estructurada desde el nuevo módulo del CEA en el Barrio Saó hasta las aulas del bloque técnico, respetando distancias de interferencia electromagnética y muros de carga, el modelo fallará frecuentemente. No posee una representación tridimensional real del espacio. Del mismo modo, operaciones aritméticas grandes o problemas de álgebra lineal específicos para la gestión de bases de datos relacionales en sistemas municipales pueden dar resultados erróneos a menos que la IA esté conectada externamente a un intérprete de código como Python.

3.5. DEPENDENCIA DE INFRAESTRUCTURA EN LA NUBE Y LATENCIA

Los modelos avanzados de Inteligencia Artificial requieren miles de tarjetas gráficas industriales (GPUs) trabajando en paralelo en gigantescos centros de datos ubicados en Estados Unidos, Europa o Asia. Por lo tanto, las aplicaciones locales desarrolladas en el municipio de Pailón dependen de una conexión a internet estable para enviar peticiones HTTP a las APIs de estos proveedores y recibir las respuestas.

Esta arquitectura plantea tres grandes problemas para un Técnico en Sistemas Informáticos regional:

1. **Latencia:** El tiempo que tarda el paquete de datos en viajar desde la computadora del CEA en el Barrio Saó hasta el servidor en el extranjero y regresar. En conexiones saturadas o inestables, esto puede demorar varios segundos, arruinando la experiencia del usuario.
2. **Costos Operativos:** El consumo de APIs comerciales se factura en dólares según la cantidad de tokens utilizados, lo cual puede ser inviable para proyectos comunitarios o instituciones públicas locales.
3. **Soberanía y Privacidad de Datos:** Al enviar información de estudiantes o registros comerciales del Barrio 24 de Septiembre a la nube, estás entregando datos confidenciales a servidores externos sujetos a legislaciones extranjeras.



3.6. EL FENÓMENO DEL "OLVIDO CATASTRÓFICO" (CATASTROPHIC FORGETTING)

Cuando un programador intenta adaptar un modelo de Inteligencia Artificial existente para que aprenda una tarea muy específica (proceso conocido como *Fine-Tuning* o Ajuste Fino) —por ejemplo, reconocer los modismos, direcciones y códigos postales específicos de los barrios de Pailón como Barrio 27 de Mayo o Barrio San Antonio—, la red neuronal se enfrenta al riesgo del **olvido catastrófico**.

Este fenómeno ocurre cuando el peso de las conexiones sinápticas artificiales del modelo se modifica drásticamente para acomodar la nueva información local. Como consecuencia, el modelo destruye o "desaprende" las capacidades generales que ya poseía (como programar, redactar formalmente o traducir idiomas). El sistema se vuelve experto en la geografía de Pailón, pero pierde su utilidad general, lo que obliga a aplicar técnicas complejas de entrenamiento balanceado.

3.7. OPACIDAD DE LOS MODELOS Y EL PROBLEMA DE LA "CAJA NEGRA"

Los modelos de aprendizaje profundo (*Deep Learning*) actuales constan de miles de millones de parámetros matemáticos interconectados. Cuando el asistente de IA del CEA toma una decisión, como clasificar a un estudiante en riesgo de reprobado el módulo informático o denegar de forma



automatizada un acceso al sistema del Barrio Residencial Norte, es humanamente imposible rastrear con exactitud la ruta matemática exacta que tomó el algoritmo para llegar a esa conclusión.

Esta falta de transparencia se denomina el **problema de la caja negra**. A diferencia del desarrollo de software tradicional, donde un Técnico puede revisar línea por línea el código fuente y los condicionales if/else para encontrar un error (*bug*), en la IA la lógica está distribuida de forma estadística. Esto genera problemas legales y éticos, ya que no se pueden auditar con facilidad los fallos del sistema ante reclamos de los usuarios.

3.8. DEGRADACIÓN DEL MODELO Y DERIVA DE DATOS (DATA DRIFT)

Un sistema de IA no es un producto estático que funciona para siempre una vez instalado. Los modelos sufren de **degradación y deriva de datos**. El mundo real cambia constantemente, pero el conocimiento del modelo se queda congelado en el día en que finalizó su entrenamiento.

Si desarrollas una IA para optimizar la logística de los mototaxis que viajan entre la estación del Barrio 24 de Septiembre y los módulos habitacionales de los barrios San Expedito y Las Misiones, y de pronto la alcaldía cambia el sentido de las calles principales o se pavimenta una nueva avenida en el Barrio Saó, la IA seguirá respondiendo con base en la realidad vieja. Sus predicciones perderán precisión paulatinamente, obligando al Técnico a implementar sistemas de monitoreo continuo y actualización de bases de datos vectoriales.

CIERRE TEÓRICO OBLIGATORIO

□ Mitos vs. Realidades

Mito	Realidad
"La Inteligencia Artificial actual es consciente, comprende lo que escribe y razona de la misma manera que un ser humano."	"La IA actual es un sistema de procesamiento estadístico avanzado que predice secuencias de datos basándose en patrones históricos, careciendo por completo de autoconciencia o comprensión real."
"Como la IA analiza millones de datos en internet, toda la información que proporciona en sus respuestas es verídica y verificada."	"La IA genera textos altamente probables según su modelo lingüístico, lo que incluye la tendencia a inventar datos falsos con apariencia"



real (alucinaciones) si no tiene la información exacta."

□ *Glosario de Términos*

1. **Token:** La unidad mínima de procesamiento de texto que utiliza un modelo de IA, correspondiente a un conjunto de caracteres o sílabas.
2. **Alucinación:** Error de los modelos generativos donde se produce una respuesta coherente en su sintaxis pero totalmente falsa o inventada en su contenido.
3. **Ventana de Contexto:** El límite máximo de datos (medido en tokens) que un modelo de IA puede retener en su memoria RAM de video a la vez durante una sesión de chat o análisis.
4. **Latencia:** El retraso temporal medido en milisegundos o segundos desde que el cliente local envía una solicitud informática hasta que recibe la respuesta del servidor central.
5. **Caja Negra:** Concepto informático que describe la opacidad de los sistemas complejos de IA, donde se conocen las entradas y las salidas, pero no los procesos lógicos internos exactos que determinaron el resultado.

□ *Ponte a Prueba*

1. Un Técnico en Sistemas Informáticos nota que el bot de atención del CEA Herman Ortiz Camargo empieza a dar respuestas inconsistentes y a ignorar las reglas dadas al principio de la sesión tras una conversación muy larga con un estudiante del Barrio Saó. ¿A qué se debe esto?
 - a) El servidor local se ha quedado sin espacio en el disco duro.
 - b) Se ha excedido el límite de la ventana de contexto del modelo de IA.
 - c) La IA ha entrado en un bucle lógico infinito por error de sintaxis en Python.
2. ¿Cuál es la causa principal de los sesgos algorítmicos en los sistemas informáticos basados en Inteligencia Artificial?



- a) El uso de lenguajes de programación antiguos como C++ en lugar de Python.
- b) Datos de entrenamiento desbalanceados que no reflejan la diversidad de la realidad local.
- c) La falta de ancho de banda en las conexiones satelitales del municipio.

3. Si necesitas que una IA realice cálculos matemáticos financieros exactos para una tienda en el Barrio Central Fátima sin riesgo de errores por predicción estadística, ¿cuál es la mejor estrategia como desarrollador?

- a) Pedirle al modelo que "piense detenidamente" y tenga cuidado con los números.
- b) Utilizar técnicas de conexión de la IA con herramientas externas, como un intérprete de código Python o una API de calculadora.
- c) Reentrenar todo el modelo de IA desde cero usando únicamente datos de Pailón.

(Respuestas correctas: 1=b, 2=b, 3=b)



VALORACIÓN



El despliegue masivo de la Inteligencia Artificial plantea profundas reflexiones que como futuro Técnico debes sopesar críticamente, más allá de las líneas de código:

1. **El Impacto Ecológico y de Residuos Electrónicos (e-Waste):** La vertiginosa carrera por actualizar el hardware informático para soportar modelos de IA locales provoca la obsolescencia prematura de computadoras perfectamente funcionales. En comunidades en desarrollo como Pailón, esto se traduce en acumulación de basura electrónica que contamina los suelos periféricos del Barrio Saó si no existen políticas de reciclaje técnico. Además, la computación en la nube consume miles de millones de litros de agua dulce y megavatios de energía eléctrica para enfriar los centros de datos, acelerando el cambio climático global.
2. **Seguridad y Privacidad Local:** Al implementar herramientas automáticas que capturen datos cotidianos de los habitantes de los barrios residenciales, iglesias y comercios de Pailón, corremos el riesgo de vulnerar el derecho a la privacidad. Enviar datos sensibles a



servidores corporativos multinacionales sin el consentimiento explícito de los usuarios finales del CEA rompe la ética profesional de la informática.

3. **Brecha Digital y Dependencia Tecnológica:** Centralizar los servicios críticos en sistemas de IA controlados por un puñado de corporaciones globales genera una vulnerabilidad sistémica. Si el municipio o el CEA dependen por completo de una API externa para gestionar sus procesos productivos o educativos, quedan a merced de cambios de precios unilaterales, bloqueos geográficos o caídas masivas de conectividad, acentuando la desigualdad tecnológica frente a las grandes capitales.



PRODUCCIÓN



LABORATORIO PRÁCTICO: SIMULACIÓN DE LIMITACIONES DE TOKENS Y CONTROL DE ALUCINACIONES EN PYTHON

Objetivo: Desarrollar un script funcional en Python que emule de forma didáctica cómo un sistema informático sufre restricciones de memoria por ventana de contexto y cómo validar datos mediante código tradicional para evitar alucinaciones geográficas en el municipio de Pailón.

Instrucciones previas: Abre el entorno de desarrollo (VS Code o IDLE Python) en tu computadora del laboratorio del CEA. Crea un archivo llamado laboratorio_limitaciones_ia.py y desarrolla el siguiente código estructurado.

Python

```
# Laboratorio_Limitaciones_ia.py
# Desarrollo de Sistemas Informáticos - CEA Herman Ortiz Camargo
# Módulo: Inteligencia Artificial Básica - Técnico en Sistemasimport sysimport
time
# Base de datos local real de los barrios autorizados en Pailón (Verificación
estricta)
BARRIOS_REALES_PAILON = [      "
Barrio Saó", "
Barrio Central Fátima", "
Barrio 24 de Septiembre",      "
Barrio Residencial Norte", "
Barrio 27 de Mayo", "
```



```

Barrio María Belén", "
Barrio San Antonio", "
Barrio Jardines de Pailón", "
Barrio Oto Waver", "
Barrio Ovidio Barberi", "
Barrio San Expedito", "
Barrio Las Misiones", "
Barrio San José"]def simular_conteo_tokens(texto_usuario):    """    Simula de
forma didáctica cómo un analizador divide el texto en tokens.    En promedio, 1
palabra en español equivale aproximadamente a 1.3 tokens.    """    palabras =
texto_usuario.split()    cantidad_tokens = int(len(palabras) * 1.3)    return
cantidad_tokensdef procesar_solicitud_con_contexto(historial_chat,
nuevo_mensaje, limite_tokens_vram):    """    Simula la restricción física de la
ventana de contexto de un servidor de IA.    Si el historial supera el límite de
tokens, elimina los mensajes más antiguos.    """    print("\n
--- PROCESANDO ENTRADA EN EL SISTEMA DE IA -
--")    # Añadimos el nuevo mensaje del usuario al historial activo
historial_chat.append({
"
rol": "
usuario", "
contenido": nuevo_mensaje}
)    # Calcular tokens totales actuales del historial    tokens_totales = 0
for mensaje in historial_chat:    tokens_totales +=
simular_conteo_tokens(mensaje["
contenido"])    print(f"[Sistema VRAM]: Tokens actuales en memoria de
contexto: {
tokens_totales}
/ Límite: {
limite_tokens_vram}
")    # Mecanismo de control de desbordamiento de la ventana de contexto
(Amnesia del modelo)    while tokens_totales > limite_tokens_vram:
print("[ALERTA SISTEMA]: Límite de tokens excedido. Aplicando descarte de
memoria antigua...")    # Se elimina el mensaje más antiguo del historial
(el primero de la lista)    mensaje_eliminado = historial_chat.pop(0)
print(f"[Olvido Catastrófico]: Se ha borrado de la memoria: '{
mensaje_eliminado['
contenido'][:30]}
...'")    # Recalcular los tokens tras la eliminación
tokens_totales = 0    for mensaje in historial_chat:
tokens_totales += simular_conteo_tokens(mensaje["
contenido"])    print(f"[Sistema VRAM]: Nuevo tamaño de la memoria interna:
{
tokens_totales}
tokens.")    return historial_chatdef
validar_respuesta_ia(barrio_solicitado):    """    Filtro de seguridad
tradicional (Capa de Software) para prevenir alucinaciones de la IA    sobre la
infraestructura geográfica del municipio de Pailón.    """    # Pasamos el texto
a minúsculas para una comparación limpia y sin fallos de tipeo    barrio_limpio

```



```

= barrio_solicitado.strip()          # Verificación de coincidencia exacta con
nuestra base de datos real del CEA    if barrio_limpio in BARRIOS_REALES_PAILON:
return f"ÉXITO: Ruta de entrega validada correctamente hacia el {
barrio_limpio}
."    else:          # Si la IA inventa un barrio, el código tradicional bloquea
la alucinación estadística          return f"
ERROR CRÍTICO (Alucinación Detectada): El destino '{
barrio_limpio}
' NO existe en la base geográfica real de Pailón."
# -
-- EJECUCIÓN PRINCIPAL DEL LABORATORIO -
--if __name__ == "__main__":    # Inicializamos una memoria de contexto muy
pequeña para poder ver el efecto del fallo en la consola
LIMITE_TOKENS_SIMULADOS = 40    memoria_ram_contexto = []
print("=====")
print("  SIMULADOR DE LIMITACIONES TECNOLÓGICAS DE IA - CEA PAILÓN  ")
print("=====")
# PASO 1: Simulación del llenado de tokens y pérdida de memoria
mensajes_simulados = [          "
Hola, soy estudiante del grupo informático del Barrio Saó y requiero soporte.",
"
Necesito verificar las conexiones de red del Barrio Central Fátima cerca de la
iglesia.",          "
Por favor guarda la clave de administrador del servidor web del CEA, la cual es:
Pailon2026@Ceao",          "
Generar reporte de conectividad del Barrio 24 de Septiembre cercano a las vías
del tren."          ]    for msg in mensajes_simulados:          time.sleep(1) #
Pausa didáctica de un segundo para observar el procesamiento en consola
memoria_ram_contexto = procesar_solicitud_con_contexto(
memoria_ram_contexto, msg, LIMITE_TOKENS_SIMULADOS          )          #
Comprobación de pérdida de información confidencial debido al límite físico de
tokens
print("\n=====")
print("[Verificación del Técnico]: Contenido final retenido en la memoria de la
IA:")    for m in memoria_ram_contexto:          print(f" -> {
m['
rol'].upper()}
: {
m['
contenido']}
")
print("=====")
# PASO 2: Simulación y mitigación de alucinaciones geográficas    print("\n
--- PRUEBA DE PREVENCIÓN DE ALUCINACIONES -
---")    barrio_inventado_por_ia = "
Barrio Subterráneo de las Flores"    barrio_correcto_local = "
Barrio 27 de Mayo"          # Procesando la alucinación simulada    print(f"
La IA intenta enviar un mototaxi a: {
barrio_inventado_por_ia}

```




```
) resultado_filtro_1 = validar_respuesta_ia(barrio_inventado_por_ia)
print(resultado_filtro_1) print(f"\nLa IA intenta enviar un mototaxi a: {
barrio_correcto_local}
") resultado_filtro_2 = validar_respuesta_ia(barrio_correcto_local)
print(resultado_filtro_2)
print("=====")
```

Tarea de Producción para el Estudiante: Corre el script en la terminal usando el comando python laboratorio_limitaciones_ia.py. Analiza cómo el mensaje número 1 y la clave secreta guardada en el mensaje número 3 desaparecen o se mantienen según el límite de tokens establecido. Modifica la variable LIMITE_TOKENS_SIMULADOS = 100 y describe por escrito en tu cuaderno técnico cómo cambia el comportamiento de retención de datos del sistema.

RECURSOS ADICIONALES

1. **OpenAI Tokenizer Tool (Herramienta Oficial de Tokenización):** Plataforma web oficial para visualizar de forma interactiva cómo los algoritmos dividen los textos en tokens y comprender el consumo exacto de recursos lógicos de hardware. Enlace de referencia: <https://platform.openai.com/tokenizer>
2. **Guía de Mitigación de Alucinaciones en Hugging Face:** Documentación técnica avanzada para Técnicos en Sistemas Informáticos sobre cómo implementar la arquitectura RAG (*Retrieval-Augmented Generation*) para conectar bases de datos locales a modelos de IA, evitando respuestas falsas. Enlace de consulta: <https://huggingface.co/docs>
3. **Repositorio de Inteligencia Artificial Local (Ollama GitHub):** Manual de despliegue de modelos de lenguaje pequeños de forma 100% offline en servidores locales, ideal para ejecutar aplicaciones informáticas dentro del CEA Herman Ortiz Camargo sin depender de conexiones a la nube externas ni sufrir problemas de latencia internacional. Enlace del proyecto: <https://github.com/ollama/ollama>